

Wyniki analizy RNA-seq – GSE116250

1. Wstęp

Celem analizy było porównanie wyników różnicowej ekspresji genów uzyskanych przy pomocy narzędzia GEO2R z wynikami własnej analizy przeprowadzonej w Pythonie dla badania GSE116250 (RNA-seq lewych komór serca). Badanie obejmuje 64 próbki: 14 serc dawców bez niewydolności (non-failing, NF), 37 przypadków kardiomiopatii rozstrzeniowej (dilated cardiomyopathy, DCM) oraz 13 przypadków kardiomiopatii niedokrwiennej (ischemic cardiomyopathy, ICM).

Własna analiza w Pythonie została ograniczona do kontrastu NF vs DCM, zgodnie z konfiguracją używaną w GEO2R.

2. Dane i przygotowanie

2.1. Źródła danych

- Dane z GEO (GSE116250):
 - plik z wynikami GEO2R: projekt/GEO/GSE116250.top.table.tsv
 - pliki pomocnicze
GEO: projekt/GEO/GSE116250_series_matrix.txt.gz, projekt/GEO/GSE116250_rpkm.txt.gz, pliki zliczeń RAW/TPM/FPKM oraz anotacje projekt/GEO/Human.GRCh38.p13.annot.tsv.gz
 - wykresy wygenerowane przez GEO2R: projekt/GEO/GSE116250_GEO_plot1.jpg – GSE116250_GEO_plot7.jpg
- Własna analiza w Pythonie:
 - macierz ekspresji RPKM: projekt/GEO/GSE116250_rpkm.txt.gz
 - metadane
próbek: projekt/GSE116250_metadata.csv (kolumny sample_id, group, gdzie group $\in \{NF, DCM, ICM\}$)

2.2. Grupy porównawcze

Na podstawie pliku GSE116250_series_matrix.txt.gz określono typ choroby dla każdej próbki. Dla analizy różnicowej ekspresji zdefiniowano grupy:

- **NF (non-failing)** – zdrowe serca dawców, próbki: NF1, NF2, ..., NF15 (14 próbek)
- **DCM (dilated cardiomyopathy)** – kardiomiopatia rozstrzeniowa, próbki: DCM2, DCM3, ..., DCM78 (37 próbek)

Próbki ICM (ICM47, ..., ICM64) zostały oznaczone w metadanych, ale nie były wykorzystywane w głównym teście NF vs DCM.

3. Analiza w GEO2R


Analiza GEO2R została przeprowadzona w interfejsie WWW GEO dla serii GSE116250 z następującą konfiguracją:



- grupa kontrolna: próbki NF
- grupa badana: próbki DCM
- metoda statystyczna: domyślny pipeline GEO2R (limma/voom, korekcja FDR Benjamini–Hochberg)

Wyniki GEO2R zostały wyeksportowane do pliku projekt/GEO/GSE116250.top.table.tsv, zawierającego m.in. kolumny:


- GeneID – identyfikator genu z NCBI
- log2FoldChange – $\log_2(\text{DCM}/\text{NF})$
- pvalue, padj – wartość p i wartość skorygowana (FDR)
- baseMean – średnia ekspresja
- Symbol, Description – symbol i opis genu

Przykładowe wizualizacje wygenerowane przez GEO2R (boxplot rozkładu ekspresji, wykres MA/volcano, histogram p-value itd.) zostały zapisane jako pliki projekt/GEO/GSE116250_GEO_plot1.jpg – GSE116250_GEO_plot7.jpg.







GSE116250: DESeq2, Padj<0.05




Total: 19224



GSE116250 Frequencies of padj-values



GSE116250 Dispersion Estimates



4. Własna analiza w Pythonie

4.1. Skrypt i biblioteki

Analiza została zaimplementowana w skrypcie `projekt/gse116250_analysis.py` z użyciem następujących pakietów:

- `pandas`, `numpy` – wczytywanie i przetwarzanie danych
- `scipy.stats` – test t-Studenta (wariant Welcha)
- `statsmodels.stats.multitest` – korekcja FDR (metoda Benjamini–Hochberg)
- `matplotlib`, `seaborn` – wizualizacje (volcano plot, histogram $\log_2FC$)

4.2. Metodyka

1. Wczytanie macierzy ekspresji RPKM z pliku `GSE116250_rpkm.txt.gz` (wiersze = geny, kolumny = próbki NF/DCM/ICM).
2. Wczytanie metadanych `GSE116250_metadata.csv` i ograniczenie analizy do próbek, dla których `group` $\in \{NF, DCM\}$.
3. Podział macierzy na dwie podmacierze: NF oraz DCM.
4. Obliczenie średniej ekspresji w NF i DCM dla każdego genu oraz $\log_2FC$:

$$\log_2FC = \log_2(\text{mean}_{DCM} + c) - \log_2(\text{mean}_{NF} + c),$$



gdzie $c = 10^{-3}$ jest małym pseudolicznikiem zabezpieczającym przed zerami.

5. Dla każdego genu wykonano test t-Studenta (Welcha) porównujący rozkład ekspresji w grupach DCM i NF.
6. Otrzymane wartości p skorygowano metodą Benjamini–Hochberg (FDR), uzyskując kolumnę `padj`.
7. Wyniki zapisano do pliku `projekt/GSE116250_DE_results_python.tsv` z kolumnami:
 - `gene` (EnsemblGeneID), `log2FC`, `pvalue`, `padj`.

4.3. Wizualizacje

Wygenerowano następujące wykresy:

- `GSE116250_volcano.png` – volcano plot (oś X: $\log_2FC$ DCM vs NF, oś Y: $-\log_{10}(p\text{-value})$, geny istotne $FDR < 0,05$ i $|\log_2FC| \geq 1$ zaznaczone na czerwono).
- `GSE116250_log2fc_hist.png` – histogram rozkładu $\log_2FC$ dla wszystkich genów.



5. Porównanie wyników GEO2R i Pythona

Do porównania obu analiz użyto skryptu projekt/analize.py, który:

1. Wczytuje wyniki GEO2R (GSE116250.top.table.tsv) i własne wyniki Pythona (GSE116250_DE_results_python.tsv).
2. Wczytuje plik anotacji Human.GRCh38.p13.annot.tsv.gz, zawierający mapowanie między:
 - GeneID (NCBI) a EnsemblGeneID oraz symbolem genu (Symbol).
3. Łączy wyniki Pythona z anotacją po EnsemblGeneID (kolumna gene) i przypisuje do nich GeneID.
4. Łączy następnie tabelę GEO2R i tabelę Pythona po wspólnym GeneID.
5. Oblicza współczynnik korelacji Pearsona między log2FC z GEO2R i log2FC z Pythona oraz liczbę genów istotnych w każdej analizie ($FDR < 0,05$).

Wyniki tego porównania (wypisane w terminalu) były następujące:

- zapisano tabelę połączonych wyników do projekt/GSE116250_geo_vs_python.tsv
- korelacja log2FC GEO2R vs Python: około **-0,499**
- liczba genów istotnych w GEO2R ($p_{adj} < 0,05$): **6780**
- liczba genów istotnych w Pythonie ($p_{adj} < 0,05$): **0**
- liczba genów istotnych w obu analizach: **0**

5.1. Interpretacja

- Ujemna korelacja ($\sim -0,5$) wskazuje, że dla części genów kierunek efektu (up/down) jest przeciwny pomiędzy GEO2R a prostą analizą w Pythonie. Sugeruje to, że zastosowany pipeline w Pythonie (RPKM + test t) nie odtwarza dobrze efektów szacowanych przez limma/voom na znormalizowanych liczbach zliczeń.
- GEO2R, korzystając z pełnego modelu limma/voom i odpowiedniej normalizacji, wykrywa dużą liczbę genów różnicowo ekspresowanych (6780 genów przy $FDR < 0,05$). W przeciwieństwie do tego, prosty model Pythonowy po korekcji FDR nie wykrył żadnego genu istotnego (0 genów z $p_{adj} < 0,05$), co oznacza znacznie mniejszą czułość.
- Różnice mogą wynikać z:
 - użycia RPKM zamiast surowych zliczeń w analizie Pythonowej,
 - zastosowania prostego testu t (Welcha) zamiast modelu liniowego z shrinkage wariancji (limma),

- specyfiki korekcji na wielokrotne testowanie przy relatywnie niewielkiej liczbie próbek.

6. Dyskusja i wnioski

1. **Porównanie metod** – GEO2R reprezentuje dojrzały pipeline statystyczny (limma/voom), przystosowany do danych RNA-seq i dużej liczby testów jednoczesnych. Własna analiza w Pythonie, oparta na RPKM i prostym teście t, jest bardziej demonstracją podejścia niż pełnowartościową alternatywą metodologiczną.
2. **Czułość i stabilność wyników** – duża liczba genów istotnych w GEO2R (6780) przy braku genów istotnych w Pythonie pokazuje, że właściwy dobór metody i normalizacji ma kluczowe znaczenie dla wykrywania subtelnych zmian ekspresji.
3. **Znaczenie biologiczne** – mimo różnic liczbowych, oba podejścia potwierdzają istnienie szerokich zmian transkrypcyjnych między sercami NF a DCM. Analiza GEO2R lepiej uwzględnia złożoność danych RNA-seq, dlatego powinna być traktowana jako główne źródło wyników biologicznych, natomiast analiza Pythonowa jako ilustracja procesu i możliwości reimplementacji pipeline'u.
4. **Możliwe rozszerzenia** – dalsze prace mogłyby obejmować:
 - użycie surowych zliczeń (GSE116250_raw_counts_GRCh38.p13_NCB1.tsv.gz) oraz bibliotek Pythonowych implementujących modele zbliżone do limma/DESeq2,
 - analizę trzech grup jednocześnie (NF, DCM, ICM),
 - integrację z informacją funkcjonalną (GO, KEGG) i analizę wzbogacenia szlaków.

7. Wykorzystanie AI

W realizacji projektu wsparto się modelem językowym (ChatGPT, model GPT-5.1), który został użyty do:

- zaproponowania odpowiedniego badania GEO (GSE116250) spełniającego kryteria zadania,
- zaplanowania struktury analizy (GEO2R + Python) oraz doboru bibliotek,
- wygenerowania szkieletu skryptów Pythona (gse116250_analysis.py, analize.py) do analizy różnicowej ekspresji i porównania wyników,
- zaproponowania struktury niniejszego raportu i sformułowań opisujących wyniki.

Ostateczne uruchomienie kodu, weryfikacja poprawności działania skryptów oraz interpretacja wyników zostały wykonane lokalnie w środowisku użytkownika.